





MODELOS DE CLASIFICACIÓN



INTEGRANTES

- Bonilla Flores Emmanuel
- García Morales Marcos
- Hernández Galicia Alberto
- Leyva Díaz Eduardo Tomás

BASE DE DATOS



ESTRUCTURA

Contiene 11 características médicas que pueden utilizarse para predecir una posible enfermedad cardiaca, fue obtenido del repositorio en línea Kaggle, consta de 918 observaciones (filas) y 12 variables (columnas).

	Age <int>	Sex <chr>	ChestPainType <chr>	RestingBP <int>	Cholesterol <int>	FastingBS <int>	RestingECG <chr>	MaxHR <int>	ExerciseAngina <chr>	Oldpeak <dbl>	ST_Slope <chr>	HeartDisease <int>
1	40	M	ATA	140	289	0	Normal	172	N	0.0	Up	0
2	49	F	NAP	160	180	0	Normal	156	N	1.0	Flat	1
3	37	M	ATA	130	283	0	ST	98	N	0.0	Up	0
4	48	F	ASY	138	214	0	Normal	108	Y	1.5	Flat	1
5	54	M	NAP	150	195	0	Normal	122	N	0.0	Up	0
6	39	M	NAP	120	339	0	Normal	170	N	0.0	Up	0
7	45	F	ATA	130	237	0	Normal	170	N	0.0	Up	0
8	54	M	ATA	110	208	0	Normal	142	N	0.0	Up	0
9	37	M	ASY	140	207	0	Normal	130	Y	1.5	Flat	1
10	48	F	ATA	120	284	0	Normal	120	N	0.0	Up	0

Fuente: <https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>

Para su construcción se integraron datos clínicos de cinco bases públicas (Statlog, Cleveland, Hungarian, Switzerland y Long Beach VA).



DESCRIPCIÓN DE VARIABLES

NUMÉRICAS

- Age: Edad del paciente (años).
- RestingBP: Presión arterial en reposo (mm Hg)
- Cholesterol: Nivel de colesterol (mg/dl).
- MaxHR: Frecuencia Cardíaca Máxima.
- Oldpeak: Depresión del segmento ST inducida por ejercicio.

	Age <int>	RestingBP <int>	Cholesterol <int>	MaxHR <int>	Oldpeak <dbl>
1	40	140	289	172	0.0
2	49	160	180	156	1.0
3	37	130	283	98	0.0
4	48	138	214	108	1.5
5	54	150	195	122	0.0
6	39	120	339	170	0.0
7	45	130	237	170	0.0
8	54	110	208	142	0.0
9	37	140	207	130	1.5
10	48	120	284	120	0.0



CATEGÓRICAS

- **Sex:** Sexo del paciente (M: Male, F: Female).
- **ChestPainType:** Tipo de dolor en el pecho, hay cuatro resultados posibles: TA - Angina Típica, ATA - Angina Atípica, NAP - Dolor no anginoso y ASY - Asintomático.
- **FastingBS:** Glucosa en ayunas, si es mayor a 120 mg/dl se le asigna el valor de 1 (hiperglucemia) y si no toma el valor de 0.
- **RestingECG:** Electrocardiograma en reposo, puede resultar en Normal, LVH y ST.
- **ExerciseAngina:** Angina inducida por ejercicio, si hay un dolor o molestia en el pecho cuando la persona hace actividad física vale 1 y si no 0.
- **ST_Slope:** Pendiente del segmento ST al final del ejercicio, puede ser Up (ascendente), Down (descendente) o Flat (plana).
- **HeartDisease:** Es el target o la clase objetivo, indica la presencia (1) o ausencia (0) de la enfermedad cardíaca.

	Sex <chr>	ChestPainType <chr>	FastingBS <int>	RestingECG <chr>
1	M	ATA	0	Normal
2	F	NAP	0	Normal
3	M	ATA	0	ST
4	F	ASY	0	Normal
5	M	NAP	0	Normal
6	M	NAP	0	Normal
7	F	ATA	0	Normal
8	M	ATA	0	Normal
9	M	ASY	0	Normal
10	F	ATA	0	Normal

ExerciseAngina <chr>	ST_Slope <chr>	HeartDisease <int>
N	Up	0
N	Flat	1
N	Up	0
Y	Flat	1
N	Up	0
N	Up	0
N	Up	0
N	Up	0
Y	Flat	1
N	Up	0



OBJETIVO

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Se desarrollarán y evaluarán cuatro modelos de clasificación supervisada a través de una Matriz de Confusión donde se permite visualizar los aciertos o errores de cada modelo, estos son:


- 1) Regresión Logística
- 2) Análisis Discriminante Cuadrático (QDA)
- 3) Árbol de Decisión
- 4) Bosque Aleatorio

Lo que se busca es seleccionar el modelo que logre una clasificación eficiente entre personas con y sin enfermedad cardíaca.

Por esta razón se dará especial énfasis a la **Sensibilidad**, métrica clave para minimizar los Falsos Negativos ya que estos representan un riesgo mayor al no detectar a personas que requieren atención médica.



LIMPIEZA DE DATOS



NOMBRE DE LAS COLUMNAS

```
```{r}
Copia
enfermedad<-heart
colnames(enfermedad)<-c("Edad","Sexo","Dolor_Pecho","Presión_Reposo","Colesterol",
 "Glucosa_Ayunas","Electrocardiograma_Reposo","Frecuencia_Máxima",
 "Angina_Ejercicio","Depresión_ST","Pendiente_ST","Enfermedad_Cardíaca")
head(enfermedad)
```
```

```
[1] "Edad"          "Sexo"          "Dolor_Pecho"
[4] "Presión_Reposo" "Colesterol"    "Glucosa_Ayunas"
[7] "Electrocardiograma_Reposo" "Frecuencia_Máxima" "Angina_Ejercicio"
[10] "Depresión_ST"  "Pendiente_ST"  "Enfermedad_Cardíaca"
```

VALORES FALTANTES

```
```{r}
colSums(is.na(enfermedad))
```
```

| Edad | Sexo | Dolor_Pecho | Presión_Reposo |
|------------------|----------------|---------------------------|---------------------|
| 0 | 0 | 0 | 0 |
| Colesterol | Glucosa_Ayunas | Electrocardiograma_Reposo | Frecuencia_Máxima |
| 0 | 0 | 0 | 0 |
| Angina_Ejercicio | Depresión_ST | Pendiente_ST | Enfermedad_Cardíaca |
| 0 | 0 | 0 | 0 |



CONVERSIÓN A FACTOR

```
# Convertirlos a Factor
enfermedad$Enfermedad_Cardíaca<-factor(enfermedad$Enfermedad_Cardíaca,
                                       levels=c(0,1),labels=c("Sin Enfermedad","Con Enfermedad"))
enfermedad$Dolor_Pecho<-factor(enfermedad$Dolor_Pecho)
enfermedad$Glucosa_Ayunas<-factor(enfermedad$Glucosa_Ayunas,levels=c(0,1),labels=c("No","Sí"))
enfermedad$Electrocardiograma_Reposo<-factor(enfermedad$Electrocardiograma_Reposo)
enfermedad$Angina_Ejercicio<-factor(enfermedad$Angina_Ejercicio,
                                    levels=c("N","Y"),labels=c("No","Sí"))
enfermedad$Pendiente_ST<-factor(enfermedad$Pendiente_ST)

glimpse(enfermedad)
```

```
Rows: 918
Columns: 12
$ Edad      <int> 40, 49, 37, 48, 54, 39, 45, 54, 37, 48, 37, 58, 39, 49, 42, 54, 38, 4...
$ Sexo      <chr> "M", "F", "M", "F", "M", "M", "F", "M", "M", "F", "F", "M", "M", "M", ...
$ Dolor_Pecho <fct> ATA, NAP, ATA, ASY, NAP, NAP, ATA, ATA, ASY, ATA, NAP, ATA, ATA, ASY, ...
$ Presión_Reposo <int> 140, 160, 130, 138, 150, 120, 130, 110, 140, 120, 130, 136, 120, 140, ...
$ Colesterol <int> 289, 180, 283, 214, 195, 339, 237, 208, 207, 284, 211, 164, 204, 234, ...
$ Glucosa_Ayunas <fct> No, No, No, No, No, No, No, No, No, No, No, No, No, No, No, No, No, N...
$ Electrocardiograma_Reposo <fct> Normal, Normal, ST, Normal, Normal, Normal, Normal, Normal, Normal, N...
$ Frecuencia_Máxima <int> 172, 156, 98, 108, 122, 170, 170, 142, 130, 120, 142, 99, 145, 140, 1...
$ Angina_Ejercicio <fct> No, No, No, Sí, No, No, No, No, Sí, No, No, Sí, No, Sí, No, No, No, N...
$ Depresión_ST <dbl> 0.0, 1.0, 0.0, 1.5, 0.0, 0.0, 0.0, 0.0, 1.5, 0.0, 0.0, 2.0, 0.0, 1.0, ...
$ Pendiente_ST <fct> Up, Flat, Up, Flat, Up, Up, Up, Up, Flat, Up, Up, Flat, Up, Flat, Up, ...
$ Enfermedad_Cardíaca <fct> Sin Enfermedad, Con Enfermedad, Sin Enfermedad, Con Enfermedad, Sin E...
```

glimpse





ANÁLISIS EXPLORATORIO



RESUMEN ESTADÍSTICO

LIBRERÍA DPLYR

```
# Variables Numéricas
num_vars <- sapply(enfermedad, is.numeric)
enfermedad_num <- enfermedad[, num_vars]

resumen<-function(x){
  y<-enfermedad_num[[x]]      # vector con los datos
  df<-data.frame(Variable=x)
  df<-df %>% mutate(Mínimo=min(y),Bigote_Inferior=boxplot.stats(y)$stats[1],
                  Q1=quantile(y,0.25),Mediana = median(y), Media = mean(y),
                  Q3=quantile(y,0.75), Bigote_Superior=boxplot.stats(y)$stats[5],
                  Máximo=max(y))
  return(df)
}
resumen_estadistico<-map_dfr(colnames(enfermedad_num),resumen)
resumen_estadistico
```

map_dfr



| Variable
<chr> | Mínimo
<dbl> | Bigote_Inferior
<dbl> | Q1
<dbl> | Mediana
<dbl> | Media
<dbl> | Q3
<dbl> | Bigote_Superior
<dbl> | Máximo
<dbl> |
|-------------------|-----------------|--------------------------|-------------|------------------|----------------|-------------|--------------------------|-----------------|
| Edad | 28.0 | 28 | 47.00 | 54.0 | 53.5108932 | 60.0 | 77.0 | 77.0 |
| Presión_Reposo | 0.0 | 92 | 120.00 | 130.0 | 132.3965142 | 140.0 | 170.0 | 200.0 |
| Colesterol | 0.0 | 85 | 173.25 | 223.0 | 198.7995643 | 267.0 | 407.0 | 603.0 |
| Frecuencia_Máxima | 60.0 | 67 | 120.00 | 138.0 | 136.8093682 | 156.0 | 202.0 | 202.0 |
| Depresión_ST | -2.6 | -2 | 0.00 | 0.6 | 0.8873638 | 1.5 | 3.7 | 6.2 |

☐ Outliers


☐ Asimetría

☐ Cuantiles




DIAGRAMAS DE CAJA Y BIGOTES


Boxplot Edad




Boxplot Presión_Reposo




Boxplot Colesterol



Boxplot Frecuencia_Máxima



Boxplot Depresión_ST








- i. Valores Atípicos
- ii. Rango Intercuartil (IQR)



HISTOGRAMAS

Representan la distribución individual de cada variable, es posible apreciar los sesgos comentados con anterioridad.



`bins = nclass.FD`




TOTAL POR CLASE

```
# Clases
proporciones<- enfermedad %>% group_by(Enfermedad_Cardíaca) %>% summarise(Total = n()) %>%
  mutate(Proporción=Total / sum(Total))
proporciones
```

A tibble: 2 × 3

| Enfermedad_Cardíaca
<fctr> | Total
<int> | Proporción
<dbl> |
|-------------------------------|----------------|---------------------|
| Sin Enfermedad | 410 | 0.4466231 |
| Con Enfermedad | 508 | 0.5533769 |

Cantidad de Datos por Clase



NIVELES

```
# Niveles
variables_factor <- sapply(enfermedad, is.factor)
for (variable in names(enfermedad)[variables_factor]) {
  cat("Variable:", variable, "\n")
  print(levels(enfermedad[[variable]]))
  cat("\n")
}
...
```

Variable: Dolor_Pecho
[1] "ASY" "ATA" "NAP" "TA"

Variable: Glucosa_Ayunas
[1] "No" "Sí"

Variable: Electrocardiograma_Reposo
[1] "LVH" "Normal" "ST"


Variable: Angina_Ejercicio
[1] "No" "Sí"

Variable: Pendiente_ST
[1] "Down" "Flat" "Up"


Variable: Enfermedad_Cardíaca
[1] "Sin Enfermedad" "Con Enfermedad"

Valores
posibles





MODELO LOGÍSTICO




Llamada con EDUARDO LEYVA DIAZ

2025-06-12 19:15 UTC

Recorded by

ALBERTO HERNANDEZ
GALICIA

SEPARACIÓN DE CLASES



BOXPLOTS

- ❑ Las personas con enfermedad cardíaca tienden a ser mayores que las que no la tienen.
- ❑ A simple vista parece que las personas con enfermedad tienen una menor frecuencia máxima.
- ❑ Para todas las variables existen valores atípicos.

GRÁFICOS DE DISPERSIÓN

- ❑ Solo para la Edad, Colesterol y Frecuencia Máxima se aprecia la separación de los puntos.

HISTOGRAMAS

- ❑ En la Presión en Reposo es donde la división de clases no es tan evidente.

CORRELACIÓN

- ❑ El valor más alto de todos es de 0.375 (valor absoluto) lo cual indica que entre las variables se está manejando una correlación baja o muy baja.

MODELO STEP

Mediante un proceso llamado selección hacia adelante y hacia atrás (**direction** = "**both**") que elimina o incluye variables en función del criterio AIC (Criterio de Información de Akaike) fue como se llegó al modelo más eficiente sin variables innecesarias y el que mejores resultados arrojó.

SUMMARY

VARIABLES SIGNIFICATIVAS

```
Call:
glm(formula = Enfermedad_Cardíaca ~ Edad + Sexo + Dolor_Pecho +
    Colesterol + Glucosa_Ayunas + Angina_Ejercicio + Depresión_ST +
    Pendiente_ST, family = binomial, data = enfermedad_train)
```

Coefficients:


| | Estimate | Std. Error | z value | Pr(> z) |
|--------------------|-----------|------------|---------|--------------|
| (Intercept) | -1.139067 | 0.959594 | -1.187 | 0.235216 |
| Edad | 0.022857 | 0.012915 | 1.770 | 0.076753 . |
| SexoM | 1.509953 | 0.304802 | 4.954 | 7.28e-07 *** |
| Dolor_PechoATA | -1.770548 | 0.359945 | -4.919 | 8.70e-07 *** |
| Dolor_PechoNAP | -1.715847 | 0.294574 | -5.825 | 5.72e-09 *** |
| Dolor_PechoTA | -1.802923 | 0.487220 | -3.700 | 0.000215 *** |
| Colesterol | -0.003445 | 0.001157 | -2.978 | 0.002904 ** |
| Glucosa_AyunasSí | 0.975918 | 0.305241 | 3.197 | 0.001388 ** |
| Angina_EjercicioSí | 0.863893 | 0.267546 | 3.229 | 0.001242 ** |
| Depresión_ST | 0.322509 | 0.128134 | 2.517 | 0.011837 * |
| Pendiente_STFlat | 0.897922 | 0.517184 | 1.736 | 0.082533 . |
| Pendiente_STUp | -1.613669 | 0.544351 | -2.964 | 0.003033 ** |

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1008.78 on 735 degrees of freedom
Residual deviance: 486.34 on 724 degrees of freedom
AIC: 510.34

Number of Fisher Scoring iterations: 5

- 
1. SexoM (hombre)
 2. Dolor_Pecho
 3. Colesterol
 4. Glucosa_Ayunas
 5. Depresión_ST
 6. Angina Ejercicio
 7. Pendiente_ST



COEFICIENTES

SUMMARY

```
Call:
glm(formula = Enfermedad_Cardíaca ~ Edad + Sexo + Dolor_Pecho +
     Colesterol + Glucosa_Ayunas + Angina_Ejercicio + Depresión_ST +
     Pendiente_ST, family = binomial, data = enfermedad_train)
```

Coefficients:

| | Estimate | Std. Error | z value | Pr(> z) |
|--------------------|-----------|------------|---------|--------------|
| (Intercept) | -1.139067 | 0.959594 | -1.187 | 0.235216 |
| Edad | 0.022857 | 0.012915 | 1.770 | 0.076753 . |
| SexoM | 1.509953 | 0.304802 | 4.954 | 7.28e-07 *** |
| Dolor_PechoATA | -1.770548 | 0.359945 | -4.919 | 8.70e-07 *** |
| Dolor_PechoNAP | -1.715847 | 0.294574 | -5.825 | 5.72e-09 *** |
| Dolor_PechoTA | -1.802923 | 0.487220 | -3.700 | 0.000215 *** |
| Colesterol | -0.003445 | 0.001157 | -2.978 | 0.002904 ** |
| Glucosa_AyunasSí | 0.975918 | 0.305241 | 3.197 | 0.001388 ** |
| Angina_EjercicioSí | 0.863893 | 0.267546 | 3.229 | 0.001242 ** |
| Depresión_ST | 0.322509 | 0.128134 | 2.517 | 0.011837 * |
| Pendiente_STFlat | 0.897922 | 0.517184 | 1.736 | 0.082533 . |
| Pendiente_STUp | -1.613669 | 0.544351 | -2.964 | 0.003033 ** |

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1008.78 on 735 degrees of freedom
Residual deviance: 486.34 on 724 degrees of freedom
AIC: 510.34

Number of Fisher Scoring iterations: 5


Variable (log-odd) (odd)

- SexoM (1.5099)(4.53)
- Dolor_Pecho (-1.7705,-1.7158,-1.8029)(0.17,0.18,0.16)
- Colesterol (-0.0034)(0.9966)
- Glucosa_AyunasSí (0.9759)(2.65)
- Angina_EjercicioSí (0.8639)(2.37)
- Depresión_ST (0.3225)(1.38)
- Pendiente_ST (0.8979,-1.6137)(2.45,0.20)
- Intercepto (-1.139067)

Un coeficiente positivo hace que el log-odd se incremente manteniendo las demás variables fijas, lo que a su vez genera que el odd (razón de probabilidad) se multiplique por $\exp(\text{coeficiente})$.



MATRIZ DE CONFUSIÓN



RESULTADOS

Verdaderos Positivos (TP): 86

Verdaderos Negativos (TN): 71

Falsos Positivos (FP): 17

Falsos Negativos (FN): 8

MÉTRICAS

Accuracy (Exactitud): 0.8626374


Precision (Precisión): 0.8349515

Recall (Sensibilidad): 0.9148936

F1 Score: 0.8730964

“De todos los pacientes que tienen la enfermedad cardiaca, el modelo logró identificar al 91.48%.”





ANÁLISIS DISCRIMINANTE CUADRÁTICO (QDA)



CONVERSIÓN A FACTOR

El modelo a realizar tomará en cuenta todas las variables, solo que para que las variables que no son numéricas sean aceptadas en la función de “**lda**” o “**qda**” de R necesitan ser convertidas factor.

```
Rows: 918
Columns: 12
$ Edad          <int> 40, 49, 37, 48, 54, 39, 45, 54, 37, 48, 37, 58, 39, 49, 42, 54, 38, 4...
$ Sexo          <chr> "M", "F", "M", "F", "M", "M", "F", "M", "M", "F", "F", "M", "M", "M", ...
$ Dolor_Pecho   <fct> ATA, NAP, ATA, ASY, NAP, NAP, ATA, ATA, ASY, ATA, NAP, ATA, ATA, ASY, ...
$ Presión_Reposo <int> 140, 160, 130, 138, 150, 120, 130, 110, 140, 120, 130, 136, 120, 140, ...
$ Colesterol     <int> 289, 180, 283, 214, 195, 339, 237, 208, 207, 284, 211, 164, 204, 234, ...
$ Glucosa_Ayunas <fct> No, No, No, No, No, No, No, No, No, No, No, No, No, No, No, No, No, N...
$ Electrocardiograma_Reposo <fct> Normal, Normal, ST, Normal, Normal, Normal, Normal, Normal, Normal, N...
$ Frecuencia_Máxima <int> 172, 156, 98, 108, 122, 170, 170, 142, 130, 120, 142, 99, 145, 140, 1...
$ Angina_Ejercicio <fct> No, No, No, Sí, No, No, No, No, Sí, No, No, Sí, No, Sí, No, No, No, N...
$ Depresión_ST   <dbl> 0.0, 1.0, 0.0, 1.5, 0.0, 0.0, 0.0, 0.0, 1.5, 0.0, 0.0, 2.0, 0.0, 1.0, ...
$ Pendiente_ST   <fct> Up, Flat, Up, Flat, Up, Up, Up, Up, Flat, Up, Up, Flat, Up, Flat, Up, ...
$ Enfermedad_Cardíaca <fct> Sin Enfermedad, Con Enfermedad, Sin Enfermedad, Con Enfermedad, Sin E...
```


glimpse

NOTA: Los supuestos del modelo se verificarán usando las variables numéricas

```
```{r}
VARIABLES NUMÉRICAS
enfermedad_train_num<-data.frame(select_if(enfermedad_train,is.numeric),
 Enfermedad_Cardíaca=enfermedad_train$Enfermedad_Cardíaca)
enfermedad_test_num<-data.frame(select_if(enfermedad_test,is.numeric),
 Enfermedad_Cardíaca=enfermedad_test$Enfermedad_Cardíaca)
```
```



SEPARACIÓN DE CLASES



BOXPLOTS

- ☐ Las personas con enfermedad cardíaca tienden a ser mayores que las que no la tienen.
- ☐ A simple vista parece que las personas con enfermedad tienen una menor frecuencia máxima.
- ☐ Para todas las variables existen valores atípicos.

GRÁFICOS DE DISPERSIÓN

- ☐ Solo para la Edad, Colesterol y Frecuencia Máxima se aprecia la separación de los puntos.

HISTOGRAMAS

- ☐ En la Presión en Reposo es donde la división de clases no es tan evidente.

CORRELACIÓN

- ☐ El valor más alto de todos es de 0.375 (valor absoluto) lo cual indica que entre las variables se está manejando una correlación baja o muy baja.

SUPUESTOS

1. NORMALIDAD UNIVARIADA (H0: Hay normalidad en cada grupo)

Kolmogorov - Sminorv (lillie.test): No se cumple la normalidad en cada grupo debido a que el valor - p es muy pequeño o igual a 0.

```
Edad          Presión_Reposo    Colesterol    Frecuencia_Máxima
Sin Enfermedad "p = 0.0278 → No normal" "p = 0 → No normal" "p = 0 → No normal" "p = 6e-04 → No normal"
Con Enfermedad "p = 0 → No normal"  "p = 0 → No normal" "p = 0 → No normal" "p = 0.016 → No normal"

Depresión_ST
Sin Enfermedad "p = 0 → No normal"
Con Enfermedad "p = 0 → No normal"

5 variables * 2 clases = 10 grupos
```

2. NORMALIDAD MULTIVARIADA (H0: Hay normalidad en conjunto)

Se utilizó el test de Henze-Zirkler (HZ) debido a que es una prueba robusta ante valores atípicos y por el tamaño de los datos.

```
$multivariate_normality
      Test Statistic p.value      MVN
1 Henze-Zirkler    3.154 <0.001 X Not normal
```

```
$univariate_normality
      Test      Variable Statistic p.value Normality
1 Anderson-Darling      Edad      0.640  0.095    ✓ Normal
2 Anderson-Darling Presión_Reposo  4.060 <0.001 X Not normal
3 Anderson-Darling      Colesterol  7.028 <0.001 X Not normal
4 Anderson-Darling Frecuencia_Máxima 1.623 <0.001 X Not normal
5 Anderson-Darling      Depresión_ST 46.500 <0.001 X Not normal
```

“Sin Enfermedad”

```
$multivariate_normality
      Test Statistic p.value      MVN
1 Henze-Zirkler    2.285 <0.001 X Not normal
```

```
$univariate_normality
      Test      Variable Statistic p.value Normality
1 Anderson-Darling      Edad      2.330 <0.001 X Not normal
2 Anderson-Darling Presión_Reposo  2.816 <0.001 X Not normal
3 Anderson-Darling      Colesterol 26.975 <0.001 X Not normal
4 Anderson-Darling Frecuencia_Máxima 0.535  0.17    ✓ Normal
5 Anderson-Darling      Depresión_ST 7.712 <0.001 X Not normal
```

“Con Enfermedad”



SUPUESTOS

3. HOMOGENEIDAD DE VARIANZAS

(H0: Las varianzas son iguales en todos los grupos)

Solo en dos grupos se obtuvo que las Varianzas entre los pacientes con y sin la enfermedad cardíaca eran iguales, pero como no ocurre esto para TODOS, entonces se concluye que este supuesto no se cumple.

leveneTest

```
```{r}
La varianzas son iguales
leveneTest(Edad~Enfermedad_Cardíaca,data=enfermedad_train_num)
La varianzas NO son iguales
leveneTest(Presión_Reposo~Enfermedad_Cardíaca,
 data=enfermedad_train_num)
La varianzas NO son iguales
leveneTest(Colesterol~Enfermedad_Cardíaca,data=enfermedad_train_num)
La varianzas son iguales
leveneTest(Frecuencia_Máxima~Enfermedad_Cardíaca,
 data=enfermedad_train_num)
La varianzas NO son iguales
leveneTest(Depresión_ST~Enfermedad_Cardíaca,
 data=enfermedad_train_num)
```
```

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  1  1.9777 0.1601
```

734

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value  Pr(>F)
group  1  7.2949 0.007075 **
```

734

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Levene's Test for Homogeneity of Variance (center = median)
```

```
      Df F value    Pr(>F)
group  1 107.45 < 2.2e-16 ***
```

734

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Levene's Test for Homogeneity of Variance (center = median)
```

```
      Df F value    Pr(>F)
group  1  0.0747 0.7848
```

734

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value    Pr(>F)
group  1  98.169 < 2.2e-16 ***
```

734

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



SUPUESTOS

4. HOMOGENEIDAD DE MATRICES DE COVARIANZA (H0: La Matriz de Covarianza es igual en todos los grupos)

La prueba a realizar para verificarlo es el test de Box M que utiliza la Chi cuadrada para calcular el valor - p, como resultado se obtuvo lo siguiente:

boxM

```
boxM(data=enfermedad_train_num[, -6], grouping=enfermedad_train_num$Enfermedad_Cardíaca)
# Las matrices de covarianza NO son iguales.
```

Box's M-test for Homogeneity of Covariance Matrices

```
data: enfermedad_train_num[, -6]
Chi-Sq (approx.) = 238.38, df = 15, p-value < 2.2e-16
```

DECISIÓN: Aplicar el Modelo de Análisis Discriminante Cuadrático (QDA) ya que los supuestos que cobran mayor importancia no se cumplen.

Como es menor al nivel de significancia hay que rechazar la hipótesis nula, es decir, tampoco ocurre que la Matriz de Covarianza es igual en todos los grupos.



MODELO QDA

Con la función **qda** se aplica el modelo una vez que se revisaron los supuestos y ya se tienen convertidas a factor las variables no numéricas, los resultados son los siguientes:

PRIOR PROBABILITIES

```
##{r}
modelo_qda<-qda(Enfermedad_Cardíaca~.,data=enfermedad_train)
modelo_qda$prior # prior probabilities
modelo_qda$means # medias
```

Sin Enfermedad Con Enfermedad
0.4375 0.5625
, , Sin Enfermedad

Probabilidad de pertenecer a una clase

MEDIAS

| Variable | Sin Enfermedad | Con Enfermedad | Diferencia Absoluta |
|---------------------|----------------|----------------|---------------------|
| Colesterol | 227.48 | 175.20 | 52.28 |
| Frecuencia Máxima | 148.39 | 127.88 | 20.50 |
| Edad | 50.55 | 55.83 | 5.28 |
| Depresión ST | 0.40 | 1.25 | 0.85 |
| Dolor Pecho – ATA | 0.34 | 0.05 | 0.30 |
| Glucosa Ayunas – Sí | 0.11 | 0.32 | 0.21 |
| Dolor Pecho – TA | 0.07 | 0.04 | 0.03 |


☐ Frecuencia Máxima

☐ Colesterol

☐ Edad



MATRIZ DE CONFUSIÓN



RESULTADOS

Verdaderos Positivos (TP): 84

Verdaderos Negativos (TN): 72

Falsos Positivos (FP): 16

Falsos Negativos (FN): 10

MÉTRICAS

Accuracy (Exactitud): 0.8571429


Precision (Precisión): 0.84

Recall (Sensibilidad): 0.893617


F1 Score: 0.8659794

“De todos los pacientes que tienen la enfermedad cardiaca, se clasificó al 89.36% como que sí la tenían.”





ÁRBOL DE DECISIÓN



MÉTODOS


Se plantearon 5 árboles distintos y se eligió el que tuvo el Recall más alto para minimizar los errores (falsos negativos), esto fue posible debido a que se manipularon los parámetros de la función `rpart` de la siguiente forma:

```
modelo <- rpart(Enfermedad_Cardíaca ~ ., data = enfermedad_train, method = "class")
```

- 1) Índice de Gini `parms = list(split = "gini")`
- 2) Máximo de Niveles `control = rpart.control(maxdepth = 3)`
- 3) Ganancia de Información `parms = list(split = "information")`
- 4) Validación cruzada `control = rpart.control(cp = 0.001, xval = 10)`
- 5) Poda del Árbol (mejor `cp`) `prune(modelo, cp = mejor_cp)`


7 niveles y 14
nodos terminales

“ÁRBOL SIN PODAR”



ÁRBOL PODADO

4 niveles y 7
nodos terminales



VARIABLES USADAS

1. Pendiente_ST
2. Colesterol
3. Frecuencia Máxima
4. Dolor_Pecho
5. Angina_Ejercicio

MEJOR CP


```
{r}  
mejor_cp <- modelo4$cptable[which.min(modelo4$cptable[, "xerror"]), "CP"]  
modelo4_podado <- prune(modelo4, cp = mejor_cp)  
...
```

[1] 0.004658385

cp = 0.00465835



MATRIZ DE CONFUSIÓN



RESULTADOS

Verdaderos Positivos (TP): 87

Verdaderos Negativos (TN): 62

Falsos Positivos (FP): 7

Falsos Negativos (FN): 26

Accuracy (Exactitud): 0.8186813


Precision (Precisión): 0.7699115

Recall (Sensibilidad): 0.9255319

F1 Score: 0.8405797

“De los pacientes que sí tienen la enfermedad, el modelo les da esa misma clasificación con un 92.55% de acierto.”








Tree 1: Cat




Tree 2: Dog



Tree 3: Cat




Tree 4: Cat



Tree 5: Cat

...




Tree n

BOSQUE ALEATORIO

HIPERPARÁMETROS


Para la construcción del Bosque Aleatorio primero se identificó la cantidad óptima de Árboles, el número de Nodos Terminales y el máximo de Variables dependiendo del impacto en el F1-Score obtenido de las predicciones OOB.

Número de Árboles




240 Árboles

Número de Nodos Terminales



56 nodos

Máximo de Variables



2 variables



APLICACIÓN DEL MODELO

Como ya se conocen los parámetros a utilizar, solo se sustituyen esos valores en la función randomForest y se genera el Bosque Aleatorio,.

```
##{r}
modelo1 <- randomForest(Enfermedad_Cardíaca ~ ., data = enfermedad_train, ntree=240, mtry=2, maxnodes=56) # Por defecto lo hace con gini
```

EXACTITUD OOB

```
##{r}
# Error OOB (ya viene incluido en el modelo)
modelo1$err.rate

exactitud_oob <- 1 - modelo1$err.rate[which.min(modelo1$err.rate[, "OOB"])]
cat("La exactitud OOB es:", round(exactitud_oob * 100, 1), "%\n")
```


```
[235,] 0.1277174    0.1739130    0.09178744
[236,] 0.1290761    0.1770186    0.09178744
[237,] 0.1290761    0.1770186    0.09178744
[238,] 0.1277174    0.1770186    0.08937198
[239,] 0.1277174    0.1770186    0.08937198
[240,] 0.1277174    0.1770186    0.08937198
La exactitud OOB es: 88 %
```

PROPORCIÓN

| | Sin Enfermedad | Con Enfermedad |
|-----|----------------|----------------|
| 3 | 1.00000000 | 0.00000000 |
| 5 | 1.00000000 | 0.00000000 |
| 6 | 0.00000000 | 1.00000000 |
| 8 | 0.04210526 | 0.9578947 |
| 10 | 1.00000000 | 0.00000000 |
| 11 | 0.04444444 | 0.9555556 |
| | Sin Enfermedad | Con Enfermedad |
| 908 | 0.90109890 | 0.09890110 |
| 909 | 0.97916667 | 0.02083333 |
| 910 | 0.77011494 | 0.22988506 |
| 913 | 0.95238095 | 0.04761905 |
| 915 | 0.05319149 | 0.94680851 |
| 916 | 0.06097561 | 0.93902439 |



MATRIZ DE CONFUSIÓN



RESULTADOS

Verdaderos Positivos (TP): 377

Verdaderos Negativos (TN): 265

Falsos Positivos (FP): 57

Falsos Negativos (FN): 37

MÉTRICAS

Accuracy (Exactitud): 0.8722826

Precision (Precisión): 0.8687

Recall (Sensibilidad): 0.9106

Puntaje F1: 0.8892

“De todos los pacientes que tienen la enfermedad cardiaca, son detectados el 91.06% de las veces.”



CONCLUSIONES

COMPARACIÓN DE MODELOS

En la siguiente tabla se puede observar los valores de la matriz de confusión, métricas más importantes y las ventajas o limitaciones que presenta cada uno de los 4 modelos finales que se utilizaron para clasificar a los pacientes que sí presentan la enfermedad cardíaca, esto nos ayudará a elegir el modelo que mejor se ajusta a los objetivos iniciales.

| Métrica | Logístico | QDA | Árbol de Decisión | Bosque Aleatorio |
|---------------------------|-----------------------------|-------------|----------------------------|-----------------------|
| Verdaderos Negativos (TN) | 86 | 84 | 87 | 377 |
| Falsos Positivos (FP) | 17 | 16 | 26 | 57 |
| Falsos Negativos (FN) | 8 | 10 | 7 | 37 |
| Verdaderos Positivos (TP) | 71 | 72 | 62 | 265 |
| Exactitud (Accuracy) | 86.26% | 85.71% | 81.86% | 87.22% |
| Precisión (Precision) | 83.49% | 84% | 76.99% | 86.87% |
| Sensibilidad (Recall) | 91.48% | 89.36% | 92.55% | 91.06% |
| F1 Score | 87.30% | 86.59% | 84.05% | 88.92% |
| Ventajas | Interpretación de Variables | Equilibrado | Mejor Recall | Superior en Métricas |
| Limitaciones | Suponer relación lineal | Supuestos | Errores (falsos positivos) | Visualización y Costo |



SELECCIÓN DEL MEJOR MODELO

El **Bosque Aleatorio** demostró ser el modelo con **mejor rendimiento global**, destacando en precisión, sensibilidad y F1 Score. Su capacidad para manejar relaciones no lineales, interacciones complejas y su resistencia al sobreajuste lo hacen ideal para aplicaciones clínicas automatizadas.

La **Regresión Logística** es una excelente alternativa cuando se prioriza la **interpretabilidad** y el análisis de factores clínicos individuales. Aunque su desempeño fue ligeramente inferior al Random Forest, su facilidad de implementación y explicación la hacen muy valiosa en la práctica médica.

Los modelos basados en **Árboles de Decisión**, en especial el **con validación cruzada**, mostraron un buen equilibrio entre interpretabilidad y rendimiento. Son ideales cuando se busca visualizar el proceso de decisión, aunque con menor precisión que los modelos de ensamble.

El **QDA** funcionó bien, pero su uso está condicionado al cumplimiento de supuestos estadísticos (normalidad y heterocedasticidad), lo que puede limitar su aplicabilidad en datos reales clínicos.

En síntesis, aunque todos los modelos ofrecieron buenos resultados, el **Bosque Aleatorio representa la mejor combinación de sensibilidad, precisión y robustez**, especialmente importante en contextos donde los errores de diagnóstico pueden tener consecuencias graves.



CONCLUSIÓN

El proceso permitió observar que, más allá de la aplicación técnica de los modelos, es fundamental contar con una base de datos bien estructurada y clínicamente coherente. El análisis cuidadoso de las variables, el tratamiento adecuado de las transformaciones y la validación del comportamiento de los algoritmos fueron aspectos centrales para asegurar la confiabilidad de los resultados. También se hizo evidente que la elección de un modelo no puede basarse únicamente en métricas de desempeño: la interpretabilidad, la robustez frente al ruido, la facilidad de implementación y el contexto de uso deben ser considerados al momento de seleccionar una herramienta predictiva.

En conjunto, este estudio refleja cómo la estadística , aplicada de manera crítica y contextualizada, puede apoyar de forma efectiva el diagnóstico clínico. La tecnología no reemplaza al criterio médico, pero sí lo complementa, ofreciendo una visión basada en evidencia y datos objetivos. A medida que estas herramientas se integren más en el ámbito de la salud, será clave mantener una mirada ética, crítica y orientada al beneficio del paciente.



**GRACIAS POR SU
ATENCIÓN**
